

利用知识图谱的推荐系统研究综述

张明星^{1,2}, 张骁雄², 刘姗姗², 田昊^{2,3}, 杨琴琴^{2,3}

1. 南京信息工程大学 电子与信息工程学院, 南京 210044

2. 国防科技大学 第六十三研究所, 南京 210007

3. 南京信息工程大学 计算机学院、软件学院、网络空间安全学院, 南京 210044

摘要:随着互联网的快速发展, 如何从海量数据中筛选实际需要的信息变得尤为重要。推荐系统作为一种信息过滤的方法, 旨在为用户推荐个性化内容。传统推荐算法中普遍存在数据稀疏和冷启动问题, 近年来, 研究者利用知识图谱中丰富的实体与关系信息, 不仅能够缓解以上问题, 同时增强了推荐系统的整体性能。利用知识图谱的推荐系统研究主要包括三方面内容: 介绍推荐系统和知识图谱的基本概念, 指出现有推荐算法的不足之处; 根据不同核心技术详细分析利用知识图谱的推荐系统研究现状, 评估不同方法的技术优势与挑战; 总结相关应用场景和数据集信息, 并展望未来发展前景。

关键词:推荐系统; 个性化内容; 知识图谱; 数据稀疏; 冷启动

文献标志码:A **中图分类号:**TP391.3 **doi:**10.3778/j.issn.1002-8331.2209-0033

Review of Recommendation Systems Using Knowledge Graph

ZHANG Mingxing^{1,2}, ZHANG Xiaoxiong², LIU Shanshan², TIAN Hao^{2,3}, YANG Qinqin^{2,3}

1. School of Electronic and Information Engineering, Nanjing University of Information Science and Technology, Nanjing 210044, China

2. The Sixty-Third Research Institute, National University of Defense Technology, Nanjing 210007, China

3. School of Computer and Software, Nanjing University of Information Science and Technology, Nanjing 210044, China

Abstract: With the rapid development of the Internet, how to obtain the needed information from huge amounts of data becomes more important. The recommendation system is a method of screening information, which aims to recommend personalized content for users. However, traditional recommendation algorithms still suffer from several challenges, such as data sparsity and cold start. In recent years, researchers have used the rich entity and relationship information in the knowledge graph to alleviate the above problems. The overall performance of the recommendation system is enhanced. This paper gives a review of the recommendation system based on knowledge graph from three aspects: Firstly, basic concepts of the recommendation system and knowledge graph are introduced. The shortcomings of the existing recommendation algorithms are pointed out. Then, the research of the recommendation system based on knowledge graph is analyzed in detail. The advantages and challenges of the different approaches are assessed. Finally, relevant application scenarios and future development prospects are summarized.

Key words: recommendation system; personalized content; knowledge graph; data sparsity; cold start

互联网的快速发展给人们的生活带来便利的同时也引起了信息过载^[1], 用户很难从海量信息中获取真正感兴趣的内容。为了增强用户体验, 推荐系统被广泛应用于视频^[2]、音乐^[3]、新闻^[4]、商品^[5]等各种推荐场景。

推荐系统旨在为用户筛选可能感兴趣的项目, 传统的协同过滤算法的实现需要利用用户和项目之间的交互信息。在现实生活中, 这些交互信息相对于海量的用户、项目数据是相当匮乏的, 尤其是电商领域, 这给推荐

基金项目:国防科技大学校科研计划项目(ZK20-46); 特殊领域青年人才托举工程项目(2021-JCJQ-QT-050)。

作者简介:张明星(1998—), 男, 硕士研究生, 研究方向为知识图谱、推荐系统; 张骁雄(1990—), 通信作者, 男, 博士, 副研究员, CCF 会员, 研究方向为知识图谱、智能决策与优化, E-mail: zxxandxx@163.com; 刘姗姗(1994—), 女, 硕士, 助理研究员, CCF 会员, 研究方向为知识图谱、自然语言处理; 田昊(1997—), 男, 硕士研究生, 研究方向为知识图谱、自然语言处理; 杨琴琴(1998—), 女, 硕士研究生, 研究方向为时序知识图谱、自然语言处理。

收稿日期:2022-09-05 **修回日期:**2022-11-03 **文章编号:**1002-8331(2023)04-0030-13

系统带来了数据稀疏问题。此外,传统推荐算法对新用户或新项目进行推荐时很难达到理想效果,即存在冷启动问题。

研究者通过引入辅助信息来解决推荐系统中普遍存在的数据稀疏和冷启动问题,例如文本^[6]、图像^[7]、标签^[8]、知识图谱(knowledge graph, KG)^[9]等。在这些辅助信息中,知识图谱不仅能够缓解以上问题,同时能够增强推荐的整体性能。具体地,利用知识图谱的推荐系统研究意义如下:

(1)建立目标项目与KG中实体的联系,从而缓解传统算法中的数据稀疏和冷启动问题;

(2)利用KG中不同项目间的语义相关性,挖掘项目间的潜在联系,提高推荐结果的准确性;

(3)挖掘KG项目的属性对用户的潜在兴趣建模,更全面地理解用户需求,丰富推荐内容的多样性;

(4)利用KG中关系路径连接用户的历史兴趣和推荐项目,增强用户对推荐结果的满意度。

鉴于知识图谱对推荐系统具有重要意义,而传统综述工作^[10-11]缺乏对最新算法性能的比较,本文对该领域最新研究进展进行综述。其特点主要体现在:分析研究现状时,讨论不同类型技术存在的问题和挑战,并总结现有的改进方案,最后采用定量的方法进行性能比较;介绍应用场景时,总结相关数据集,针对不同推荐场景的特点讨论其对应的算法方案,并对比不同算法在应用过程中的优缺点。

1 研究概述

本文首先从推荐系统和知识图谱两方面进行背景介绍,通过阐述传统推荐算法存在的问题,进一步说明知识图谱引入到推荐系统中的重要性,随后给出利用知识图谱的推荐系统问题定义。

1.1 推荐系统

推荐系统是一种筛选信息的方法,通过用户-项目的历史交互信息理解项目属性和用户偏好,并基于捕获的用户偏好为用户推荐可能感兴趣的项目。按照不同的算法分类,可以将推荐系统分为基于内容的推荐、基于协同过滤的推荐以及混合推荐^[12]。

基于内容的推荐算法从项目的辅助信息中提取属性,并通过用户历史兴趣项目的特征获取用户表示。该方法通过计算项目之间的相似性,可以为用户推荐与曾经喜欢过的项目相似的新项目,但存在新用户的冷启动问题。此外提取项目属性是一个复杂的过程,并直接影响推荐结果的准确性^[10];推荐项目之间相似性较高,缺乏多样性,很难达到让用户满意的效果。

基于协同过滤的推荐算法主要包含了两类技术,即基于内存的协同过滤和基于模型的协同过滤^[13]。基于内存的协同过滤利用用户-项目交互信息学习不同用户

之间的相似性,并向目标用户推荐与其相似的用户所喜欢的项目。此外,一些方法考虑学习项目之间的相似性,并根据用户的历史偏好为用户推荐相似项目。基于内存的协同过滤方法避免了项目特征的提取过程,但所利用的用户-项目的交互信息在现实环境中非常稀疏。基于模型的协同过滤方法利用机器学习的思想建立推理模型,从而预测用户对项目的评分,例如矩阵分解模型^[14]将用户-项目的交互矩阵分解成用户矩阵和项目矩阵,通过矩阵乘法运算预测每个用户对不同项目的评分。这类方法通过少量交互信息构建推荐系统模型,从而有效缓解数据稀疏问题。

混合推荐算法一方面可以融合多种技术,例如文献[15]将深度学习应用于混合推荐,将深度学习与机器学习模型相结合,从多个角度学习用户和项目之间的交互,从而更全面地理解用户偏好,增强模型的泛化能力;另一方面可以融合多方面信息,文献[16]通过将知识图谱中结构化信息与文本信息结合来丰富项目的语义表示,构建了一个高效的混合推荐系统。混合推荐系统弥补了不同技术的缺点,增强用户、项目的特征表示,能够有效缓解传统推荐算法中普遍存在的数据稀疏和冷启动问题。

1.2 知识图谱

知识图谱的本质是对知识的结构化表示,其概念最早由Google公司提出,目的在于提升搜索引擎的搜索质量,增强用户搜索体验^[11]。知识图谱由节点和边组成,其中节点表示实体或概念,边表示属性或关系。知识图谱通常以三元组<头实体-关系-尾实体>的形式存储,可以最直观地表述客观事实和实体间的关系。例如<战狼-导演-吴京>表示“吴京”和电影“战狼”之间存在“导演”关系。随着互联网的快速发展,知识图谱被广泛应用到搜索引擎、推荐系统、智能问答等领域。

用于推荐任务的知识图谱可以分为两类,其中最普遍的一种如文献[17-18]等构建的项目知识图谱(item knowledge graph, IKG)。此外,文献[19-20]等将用户-项目间存在的不同交互类型视为多种关系,从而构建用户-项目交互的知识图谱,并与项目知识图谱集成为统一的协同知识图谱(collaborative knowledge graph, CKG)进行推荐。

将知识图谱引入到推荐系统作为一种混合推荐方法能够弥补传统算法的不足。如图1,利用知识图谱中提供的电影“长津湖”“战狼”的属性信息,可以缓解传统算法中的数据稀疏和冷启动问题。利用额外的属性信息,学习项目之间的相似性,提高推荐结果的准确性。同时,根据“长津湖”的属性信息,可以为喜欢“长津湖”的用户推荐“陈凯歌”导演或“吴京”主演的其他影视作品,丰富推荐内容的多样性。此外,“吴京”同时出演了“长津湖”和“战狼”,且两部电影都属于战争片,因此推荐“战狼”给喜欢“长津湖”的用户更容易满足用户需求。




图1 知识图谱示例

Fig.1 Knowledge graph example

1.3 问题定义

一种典型的利用知识图谱的推荐系统定义如下： $U=\{u_1, u_2, \dots\}$ 和 $I=\{i_1, i_2, \dots\}$ 分别表示用户和项目的集合，利用用户的反馈信息构建用户-项目的交互矩阵 Y ，其中 y_{ui} 表示用户 u 和项目 i 之间存在交互。此外， V 和 R 分别表示知识图谱中的实体集合和关系集合，知识图谱 $G=\{(h, r, t)|h, t \in V, r \in R\}$ 表示为三元组的集合，每一个三元组表示头实体 h 与尾实体 t 之间存在关系 r 。推荐系统的目标是通过定义的交互矩阵 Y 和知识图谱 G ，预测目标用户与目标项目交互的概率。图2为利用知识图谱的推荐系统示意图。根据已知的用户-项目交互数据和项目知识图谱预测未知的用户-项目交互的概率得分，其中每个项目都能够在知识图谱中找到对应的项目实体和属性信息，从而进行合理推荐。

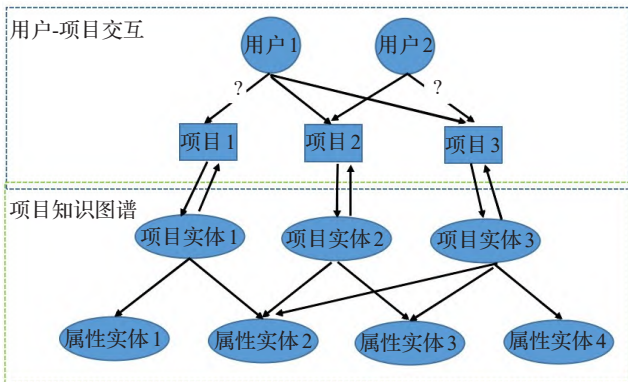


图2 利用知识图谱的推荐系统示意图

Fig.2 Recommendation example based on knowledge graph

2 研究现状

现有利用知识图谱的推荐系统主要依赖三种核心技术，即知识图谱嵌入、路径实例挖掘以及高阶信息聚合。为了方便阅读和查询，表1对部分相关文献进行了整理，其主要来源于推荐系统领域的顶级会议和期刊。

表1 相关文献分类表

Table 1 Classification of relevant references

技术类型	相关文献
知识图谱嵌入	[17][18][20][21][22][23][24][25][26][27][28][29][30]
路径实例挖掘	[31][32][33][34][35][36][37][38][39]
高阶信息聚合	[40][41][42][43][44][45][46][47][48][49][50][51][52]

2.1 知识图谱嵌入

知识图谱嵌入利用图嵌入技术获取用户和项目表示。文献[53]提出将知识图谱嵌入技术分为两类，基于距离的翻译嵌入(translational distance models)和基于语义匹配的嵌入(semantic matching models)。

2.1.1 基本理论与方法

基于距离的翻译模型将实体和关系表示为连续的向量空间，并计算两个实体之间的距离来衡量一个三元组表述事实的合理性。在基于距离的翻译模型中，Trans系列算法如TransE^[54]、TransH^[55]、TransR^[56]、TransD^[57]被广泛应用。例如，文献[21]利用改进后的TransR算法学习项目实体的嵌入向量，通过结合知识图谱嵌入和协同过滤算法的损失函数获得最终的实体嵌入表示，相较于基线模型，在MovieLens-1M和Amazon-Book数据集上recall@50分别提高2.46%和7.66%。KTUP(knowledge-enhanced translation-based user preference)模型^[22]利用知识图谱中的关系为用户的偏好建模，使用TransH算法更新用户和项目的表示，最后将推荐任务和知识图谱补全结合，同时提高这两个任务的性能。此外，基于距离的翻译嵌入还包括高斯嵌入KG2E^[58]、TransG^[59]等。

基于语义匹配模型通过向量空间中实体和关系的潜在语义表示计算相似性评分，来衡量三元组表述事实的合理性^[53]。DKRL(description-embodied knowledge representation learning)^[23]利用DistMult^[60]算法，将每个关系编码为一个对角矩阵，并考虑实体的潜在特征和关系表示的成对交互，以计算三元组的合理性。MSAKR(multi-task feature learning approach for social relationship and knowledge graph enhanced recommendation)模型^[24]将基于语义匹配的知识图谱学习模型与用户社交关系融合，实现在豆瓣电影数据集上较融合社交关系的模型^[61]AUC(area under curve)及Acc(accuracy)指标分别提升5.80%和2.10%。随着神经网络技术的发展，一些新的语义匹配模型SME(semantic matching energy)^[62]、MLP(multilayer perceptron)^[63]被广泛应用。

2.1.2 现有挑战与改进

传统的基于知识图谱嵌入的推荐方法^[18,20]将图嵌入模块和推荐模块视为两个单独的部分，首先通过图嵌入模块学习知识图谱中实体和关系的向量表示，再将预先训练的实体表示输入到推荐模块进行预测。这种低耦合的依次训练方式更适合知识图谱内部的任务，如知识图谱补全、关系预测等。为了更好地结合两个模块，文献[17,25]将图嵌入模块的损失结合到推荐算法的目标函数中，进行联合训练。通过联合学习的方式，推荐模块能够对图嵌入模块提供反馈，从而更利于实体的特征学习，提升推荐系统的整体性能。文献[26-27]采用多任务学习的框架，利用知识图谱嵌入任务来辅助推荐任务构成交替训练方式。两个任务通过中间的交叉压缩单

元关联,明确建模项目和实体特征之间的高阶交互,并自动共享潜在特征。通过交叉压缩单元,项目和实体的表示可以相互补充,进而避免过拟合并提高模型泛化能力。

另一方面,知识图谱嵌入方法不能充分利用知识图谱中的高阶信息。因此通常需要引入语义信息丰富推荐系统中的项目表示。例如,文献[28]结合图嵌入和上下文的单词表示进行混合推荐,首先基于 TransE 和 TransH 获得知识图谱中的实体和关系的结构化表示,然后使用 **BERT** (bidirectional encoder representation from transformers)^[64] 文本编码策略获得实体的语义信息,最后学习基于图谱和单词嵌入的用户和项目的混合表示,并通过预测用户对项目的兴趣来进行合理的推荐。文献[29]提出融合标签与知识图谱的方法,并融合注意力和自注意力机制,通过标签和实体为物品特征分配混合注意力权重,从而实现推荐准确性的提升。文献[30]整合知识图谱与项目共现数据(例如 item1、item2、co-buy)进行推荐,其中共现数据包含了丰富的项目-项目相似性信息,从而弥补知识图谱中有向关系无法揭示的潜在关系,使得模型 HR(hit ratio)@20 指标在电影数据集上提升 3.96%。

2.2 路径实例挖掘

路径实例挖掘方法利用知识图谱中关系信息连接用户和目标项目来增强推荐,通常需要手动设置元路径以便进一步挖掘用户-项目之间的路径实例。

2.2.1 基本理论与方法

PER (personalized entity recommendation) 模型^[31]构建 user-item-*item 的元路径形式,然后沿着不同的元路径扩散用户偏好,为用户和项目生成潜在特征。文献[32]提出 MG-HIF (multi-graph heterogeneous interaction fusion) 模型,融合交互信息和用户社交网络,利用元路径生成多个不同顶点的序列,最后通过互相关方法学习用户-项目的表示。文献[33]基于元路径的随机游走生成能够捕获不同类型节点之间的语义和结构相关性路径。考虑到随机游走策略生成的路径实例可能带来干扰信息,MCRec (meta-path based context for recommendation) 模型^[34]使用基于优先级的采样技术来选择高质量的路径实例,并通过 SVDFeature (singular value decomposition)^[65]在图上训练每个节点的表达,计算当前节点到下一个候选节点的相似度作为优先度。最后,根据优先度得分对所有候选路径实例进行排序,在 MovieLens 数据集上 NDCG@10 指标达到 0.69,提高了推荐系统的有效性和可解释性。

知识图谱中的路径实例包含用户-项目之间的远程语义连接,使得推荐系统具有较强的可解释性。文献[35]利用强化学习方法,根据用户的历史偏好信息,有效地推理高质量路径进行推荐。文献[36]提出了时间元路

径引导的可解释推荐,它考虑了用户在序列感知推荐的全局知识图谱上行为的动态性,并通过注意力机制来探索用户-项目和项目-项目的元路径进行可解释的推荐,提高了用户对推荐结果的满意程度。

2.2.2 现有挑战与改进

基于元路径的推荐算法的性能非常依赖元路径的质量,因此通常需要借助领域专业知识进行辅助推荐。此外,每个提取的路径都是独立建模的,不能充分利用知识图谱隐含的结构信息。文献[37]引入元图的概念,首先计算元图引导下用户和项目之间的相似度,然后利用无监督的矩阵分解技术获得用户和项目的潜在向量,最后使用因子分解机^[14]技术整合从不同元图中计算出的用户和项目向量集,从而进行推荐。相较于基于元路径的 HeteRec (heterogeneous information network approach for recommendation)^[31]模型,在 Yelp 数据集上均方根误差下降 4.20%。与元路径方法不同,元图只需考虑目标用户和推荐项目,而不限制两个节点之间的实体性质,因此在预测过程中加入了更复杂的语义以增强推荐系统的整体性能。

元图的概念在文献[38-39]中也被称为元结构。其中文献[38]考虑到元结构的数量随着其大小和节点类型的数量呈指数增长,因此采用遗传算法来自动搜索元结构,并设计基于注意力机制的多视图图卷积网络模块来动态地融合来自不同元结构的信息。相较于手动设置元路径的基线模型,利用优化后的元结构进行推荐在大多数评估指标上实现了超过 6% 的性能提升。

2.3 高阶信息聚合

基于知识图谱高阶信息聚合的推荐方法将嵌入的语义信息与知识图谱中的路径结合起来,通过多个邻居丰富用户和项目的表示。

2.3.1 基本理论与方法

RippleNet 模型^[40]认为用户历史交互过的项目能够在一定程度上表示用户偏好,将用户历史兴趣集与知识图谱中的实体对齐,视为 KG 中的种子集合,然后沿着 KG 链接迭代地扩展用户兴趣,捕提高阶语义信息以构建用户的向量表示。文献[41]在该模型的基础上引入注意力机制,使得节点聚合的过程中更关注相似度高的节点,得到更准确的用户向量加权表示,与 RippleNet 模型相比,在电影、图书、音乐数据集上准确率分别提升 1.9%、0.8% 和 5.8%。

文献[42]受到图卷积网络的启发,提出了知识图谱卷积网络 (knowledge graph convolutional networks, **KGCN**)。具体的, KGCN 首先设计了一种注意力机制用于描述关系对用户的重要性得分,为给定的用户识别重要关系信息;随后,将知识图谱转换为用户特定的加权图,通过注意力得分加权得到目标项目的邻域表示;最后,通过传播和聚合邻域信息来计算项目节点的嵌入

表示进行推荐。**KGCN-LS**^[43]针对KGCN中容易出现过拟合的问题增加标签平滑(label smoothness, LS)机制,将标签平滑度作为附加的正则化来指导学习过程,实现更好的泛化。

CKAN(collaborative knowledge-aware attentive network)模型^[44]采用RippleNet的思想,利用用户-项目的交互信息为用户和项目分别构建初始实体集,利用KG聚合高阶关系获得用户项目的邻域表示。考虑到初始实体集与用户和项目有很强的联系,用户和项目最终表示还需要结合初始集的实体表示,特别的,项目表示考虑其实体本身的原始表示。**CKAN**采用的传播策略对交互信息和KG进行编码,使得用户和项目的表示都能充分利用两部分信息,在四个数据集上的实验验证了比其他基于高阶信息聚合模型的优越性。

2.3.2 现有挑战与改进

现有的高阶信息聚合方案大多是基于节点的,即从相邻节点收集信息,而不区分信息来自哪些路径,因此不足以捕获关系之间的相互作用。与以上基于节点聚合的机制不同,**KGIN**(knowledge graph-based intent network)模型^[45]将关系路径视为一个信息通道,并将每个通道嵌入到一个表示向量中。首先利用KG关系的注意组合来建立用户选择项目的意图集合,因此目标用户可以表示为不同意图的加权和。然后结合相连实体的关系感知信息来生成项目表示。这种表示反映了关系之间的相互作用,并保留了路径的整体语义。

知识图谱中的一个实体通常存在于多个三元组中,因此该类方法^[19, 44]在聚合高阶的信息时,随着跳数增加,计算量呈指数型增长。一些模型^[40, 42]通过固定采样大小来减少计算开销,通过随机选取样本的方式选择性聚合邻域信息。这种采样方式无法区分邻居实体的重要性,此外,将采样过程和推荐过程分离限制了模型端到端的训练方式。文献[66]强调在抽样过程中关系的重要性,基于关系计算目标项目和邻居实体的相关性分数,按照相关性得分选择 k 个最相关的邻居实体,并将采样过程和推荐过程进行联合优化,因此模型可以正确地选择有价值的信息进行聚合,在聚合8个邻居的情况下获得最佳性能。文献[46]使用优化的图卷积网络,去除特征转换和非线性激活模块,模型在不影响性能的情况下,时间复杂度优化了56%左右。

另一方面,聚合知识图谱中与推荐无关的信息(称为噪声)给模型性能带来了干扰。**AKUPM**(attention-enhanced knowledge-aware user preference model)模型^[47]为了过滤掉噪声,利用知识图谱中用户的点击历史传播,这样每个合并的实体都与用户相关。**ATBRG**(adaptive target behavior relational graph)模型^[5]根据用户历史行为和目标项目进行连接和剪枝操作来提取目标-行为关系图,所提取的关系子图自适应地保留连

接用户行为和项目项目的有用信息,推动模型提供更有有效的推荐。**KGCL**(knowledge graph contrastive learning)模型^[48]将对比学习方法应用到知识图谱表示学习中,首先在项目知识图谱上采用随机数据增强方案生成两个相关的数据视图,并推导项目在不同视图上表示的一致性,以反映该项目对噪声扰动的不变性。在信息聚合模块中选择一致性得分越高的项目,则受噪声影响越小,对用户真实兴趣的建模贡献越大。类似地,**MCCLK**(multi-level cross-view contrastive learning)模型^[49]将用户-项目-实体图拆分为用户-项目和项目-实体两个子图,通过子图之间以及子图与全局视图间的交叉对比学习,在三个数据集上相较于最优的**KGIN**模型^[45],AUC指标提升1.61%~3.11%。

2.4 实验对比

为了进一步对比不同方法的性能和复杂度,本节基于**Recbole**框架^[67],在MovieLens-100k数据集上对常见的几种基线模型的实验结果进行讨论。如表2,利用召回率(Recall)和准确率(Precision)对前10项推荐结果进行评估。

表2 常见的几种基线模型对比

Table 2 Comparison of several common baseline models

模型名称	Recall@10	Precision@10	Time(s/epoch)
ItemKNN	0.159 5	0.231 3	0.86
KTUP	0.141 1(-9.7%)	0.230 6(-0.3%)	1.64
MKR	0.161 3(+1.1%)	0.254 0(+9.8%)	3.19
RippleNet-1hop	0.148 7(-6.8%)	0.246 6(+6.6%)	1.87
RippleNet-2hop	0.159 9(+0.2%)	0.247 9(+7.2%)	7.55
KGCN	0.169 1(+6.1%)	0.271 3(+17.3%)	1.43
KGAT	0.196 7(+23.3%)	0.308 3(+33.3%)	2.52
KGIN-1hop	0.205 0(+28.5%)	0.317 7(+37.3%)	2.81
KGIN-2hop	0.184 3(+15.5%)	0.279 2(+20.7%)	4.44
KGIN-3hop	0.163 2(+2.3%)	0.249 4(+7.8%)	12.40

ItemKNN(item K -nearest neighbor)^[68]是基于 k 近邻和项目相似度的传统协同过滤方法,将它作为基线模型与基于KG的方法进行对比。从实验结果来看,大多数基于KG的模型在Recall@10和Precision@10指标上都能超过传统的协同过滤。然而,对知识图谱中实体信息的学习需要花费额外的时间,尤其是对高阶信息进行聚合时,训练时间呈指数形式增长。另外,利用知识图谱嵌入技术的**KTUP**模型^[22]和**MKR**(multi-task learning for recommendation)模型^[27]的性能提升并不明显,这是因为模型没有充分利用知识图谱的知识,同时知识图谱中可能存在与推荐无关的干扰信息,而现有模型对噪声信息的处理缺乏更深入的研究。

相比于利用知识图谱嵌入的推荐方法,高阶信息聚合方法**RippleNet**^[40]、**KGCN**^[42]、**KGAT**(knowledge graph attention network)^[19]、**KGIN**^[45]通过对项目邻居节点的聚合,能够有效地提升推荐性能,尤其是后三者通过注意

力机制识别项目周围实体的重要性,相比于RippleNet模型的随机选择邻居方式更具有优势。

此外,为了探讨知识图谱高阶信息对推荐结果的影响,在RippleNet模型和KGIN模型上进行对比实验。RippleNet-2hop中通过将项目周围的二阶实体也进行聚合,从而提高了召回率和准确率。而在KGIN模型中由于实体数量随着阶数的增加呈指数形式增长,同时带来更多的噪声信息,不仅耗费更长的训练时间,模型性能也受到一定影响。在实际应用中,需要同时兼顾模型性能和训练时间,因此,高阶信息聚合的方法通常设置1-2阶的信息聚合即可。

2.5 研究现状总结

虽然利用知识图谱的推荐系统存在准确性高、可解释性强等优点,但在实际应用时,应结合推荐模型的复杂度和不同算法的性能效果等因素进行模型选择。为方便研究者对比和选择模型,如图3,对三类方法之间的区别和联系进行总结。

CKE(collaborative knowledge base embedding)^[17]是一种结合KG、文本和图像信息,通过KG嵌入任务和推荐任务依次训练的模型。KTUP^[22]、MKR^[27]等模型从训练方式上对模型进行改进,使两个任务能够更好地融合。DKN(deep knowledge-aware network)^[18]、UGRec(undirected relations for recommendation)^[30]、CTK(combining tag and knowledge graph for recommendation)^[29]等模型引入额外的信息与KG结合,从而缓解数据稀疏问题。DKRL^[23]模型使用语义匹配的嵌入方式进行推荐,MSAKR^[24]模型将这种嵌入方式和推荐任务统一到多任务学习框架中,增强推荐性能。

PER^[31]是基于元路径的推荐方法,通过元路径下的随机游走连接用户和项目进行推荐,提升推荐结果的可解释性。为获取高质量的路径,McRec^[34]模型通过注意力机制进行采样。PGPR(policy-guided path reasoning)^[35]、TMER(temporal meta-path guided explainable recommendation)^[36]模型利用强化学习在决策任务中的优势,将强化学习和深度游走策略用在路径选择上,进一步提高路径采样的效率和质量。GEMS(genetic meta-structure

search)^[38]和FMG(factorization machines on graph)^[39]将元路径扩展到元图,避免繁杂的元路径设置过程,其中GEMS利用遗传算法在元图中搜索并优化元路径,实现超过6%的性能收益。

基于高阶信息聚合的方法加强了对知识图谱中高阶信息的利用,同时避免了手动设置元路径操作。RippleNet^[40]是较早期的研究,利用KG中项目属性和关系捕获用户的兴趣表示。KGCN^[42]、CKAN^[44]等模型利用类似思想来丰富目标项目表示。为区分用户、项目周围实体的重要性,KGAT^[19]模型引入了注意力机制,但信息聚合的过程中仍引入干扰信息。KGCL^[48]、KCAN^[46]分别利用对比学习机制和子图提取方法来缓解KG中噪声干扰问题。AKTUP^[47]模型沿用RippleNet模型的节点聚合机制挖掘用户偏好,该方法缺乏用户和目标项目之间的路径连接,KGIN^[45]模型从关系路径聚合的思路进行改进,并细粒度地挖掘用户与项目交互背后的意图,提升推荐结果可解释性。

针对不同类型的推荐算法的优点、存在的问题与挑战以及现有解决方案进行总结。知识图谱嵌入方法具有灵活性,方便模型在多种场景下的迁移使用。推荐系统的运算速度快,整体效率高,但缺乏对高阶信息的利用,实体的表示受限。路径实例挖掘方法建立用户-项目之间的路径连接,增强了推荐结果的可解释性。但该方法需要手动设置元路径,同时挖掘出的路径实例质量严重影响最终的推荐结果。高阶信息聚合的方法充分结合前两者的优势,但不可避免地带来了计算成本过高、噪声干扰等问题。现有研究虽然通过固定采样大小、提取相关子图等方法进行改善,但效果并不理想,如何设置优先级采样方法进行信息聚合需要进一步探索。

3 应用场景

近年来,随着人工智能技术的不断发展,知识图谱的相关技术成为当下研究的热点。一系列大规模的通用知识图谱,例如DBpedia^[69]、Freebase^[70]、YAGO^[71]等已被广泛应用。研究者可以通过不同领域的推荐项目与知识图谱中的实体匹配,从而进行推荐。例如,文献[72]

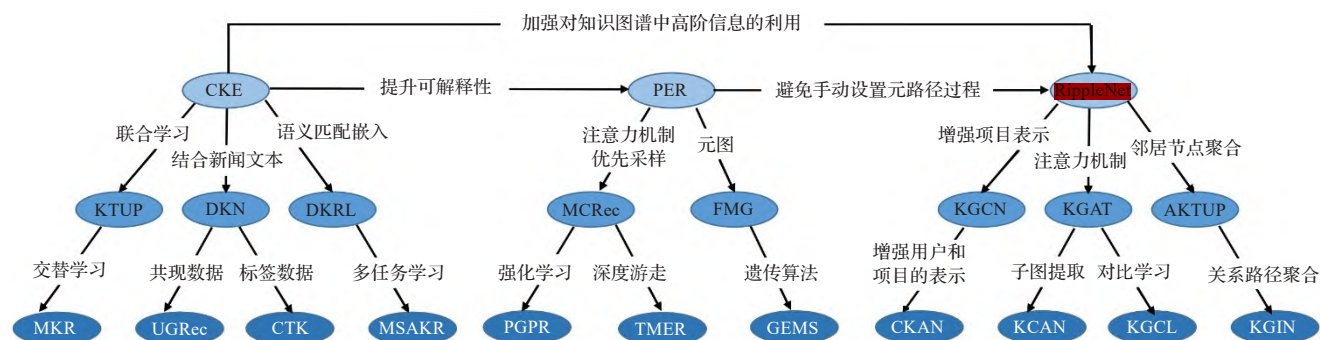


图3 不同类型方法之间的联系

Fig.3 Connections between different types of methods

利用项目标题匹配的方式从公开知识图谱 Freebase^[70]中构建 Last.FM^[73]和 Amazon-Book^[74]的知识图谱。

鉴于不同的应用场景存在不同的特点,本文对主要应用场景进行分析,并总结不同领域的相关数据集和对应的推荐方案。

3.1 视频、音乐、图书等推荐

电影、音乐、图书等推荐是最常见的推荐任务。现有的电影相关数据集主要有 MovieLens^[75]和 Douban-Movie^[76]两个数据集。音乐推荐可以基于 Last.FM^[73]实现。

图书相关的数据集主要包括 Intent Book^[77]、DBbook^[78]、Amazon-Book^[74]、Book-Crossing^[79]等。

这类任务的共同特点在于用户的兴趣不会在短时间内发生变化。因此,如何建模用户的长期兴趣偏好至关重要。传统的思路通过用户和项目的历史交互信息学习用户兴趣。例如,文献[22]将知识图谱中关系视为用户选择项目的不同原因,但不同关系表示的用户兴趣往往是独立的,模型缺乏对用户兴趣的内在联系进行建模。文献[45]融合知识图谱中的不同关系构建用户的意图网络,从而利用不同的意图加权表示用户的整体兴趣。该方法依赖于用户项目交互数据的丰富监督信号,在数据稀疏的情况下,用户偏好建模受限。近年来,会话推荐系统引起了研究者的广泛关注。会话推荐系统通过自然语言对话学习用户的兴趣偏好,进而为用户提供高质量的推荐^[78]。文献[79]利用基于知识图谱的语义融合技术改进会话推荐系统。首先构建了一个面向单词的概念知识图谱和一个用于推荐的项目知识图谱,然后利用图神经网络分别学习两个 KG 的节点嵌入,最后利用最大互信息方法^[80]弥补两个 KG 的语义差异,从而在项目推荐和话语生成方面获得更好的性能。

3.2 新闻推荐

新闻推荐不同于上述几种常见的推荐任务,通常需要考虑新闻信息的浓缩性和时效性。新闻推荐可以使用 Bing-News^[81]、MIND(Microsoft news dataset)^[81]两个数据集。其中 MIND 是由微软新闻的用户点击日志构建的大规模公开数据集,每一篇新闻都有丰富的标题、摘要、正文等文本内容。

新闻文本具有准确简洁等特点,因此结合知识图谱的新闻推荐通常需要和自然语言处理技术结合起来生成高质量的文本表示。例如,文献[51]首先利用知识图谱注意网络(KGAT)^[19]的思想聚合邻域信息来丰富知识图谱中的实体嵌入,然后从文档中提取实体的位置、频率、类别等信息用于丰富实体表示,最后在原始文档表示的指导下利用注意力机制对实体嵌入进行聚合,得到新的文档向量用于新闻推荐。该模型增强新闻文章的表示能力,从而提升推荐系统准确性。但该模型忽视了新闻的时效性,用户的兴趣可能随着新闻热点不断发生变化。文献[82]结合个性化匹配评分和新闻流行度

评分对候选新闻进行排名。因此模型能够同时捕捉到新闻热点和用户兴趣来缓解个性化新闻推荐的冷启动和多样性问题。在真实的应用场景下,由于好奇心理,用户可能受新闻标题的影响随意点击新闻,影响模型对用户兴趣建模。文献[52]通过知识剪裁操作将与用户历史兴趣无关的实体删除,并采用图注意网络^[83]的思想进行图卷积,增强具有相关关系的种子实体。因此,可以根据用户在长期和短期内的历史点击推导出用户的长期和短期兴趣表示。

3.3 商品推荐

商品推荐作为另一种特殊的应用场景,需要考虑用户的需求变化。商品推荐的数据集主要来自于电商网站 Amazon。此外,文献[84]利用 Alibaba-iFashion^[85]进行研究,收集了来自在线购物系统的时尚服装数据。相比于其他推荐场景,商品数据集具有数据量大和数据稀疏的特点。

从实际情况考虑,用户倾向于短期内购买互补的物品而不是替代品,如图4,当获取到用户购买手机1的信息后,短期内应倾向于推荐互补商品耳机或充电器,而不是另一款相似的手机2。序列化推荐任务将用户-项目之间的交互信息建模为动态的序列,从而捕捉用户的需求变化。文献[86]通过对基于循环神经网络(recurrent neural network, RNN)的推荐方法进行分析和改进,提出混合神经网络与知识图谱的序列推荐,相比基于 RNN 的算法加入 KG 和注意力机制,虽然提高了推荐的准确率,但需要较长的训练时间和更昂贵的硬件设备支持。文献[87]提出一种动态建模的方式,针对互补商品和替代商品设计两种不同的时间核函数,从而根据历史序列中是否存在同类项目以及所经过的时间来满足不同时期的推荐需求,然而不同商品(例如生活用品和电子设备)的使用时间存在较大差异,无法使用统一的核函数进行处理。




图4 商品推荐示例

Fig.4 Illustration of commodity recommendation

3.4 POI推荐

POI(point of interest)推荐即兴趣点推荐,旨在为用户推荐可能感兴趣的地点,例如餐厅、影院、酒店等^[10]。Yelp Challenge^[88]数据集包含了 POI 的种类、位置等信息,以及用户对历史去过 POI 的评论、评分等数据。

与商品推荐类似,POI推荐也存在数据稀疏和用户冷启动问题。此外,POI推荐需要考虑时间因素和位置因素。例如,用户在中午可能选择附近的餐厅就餐,而晚上更倾向于去酒店休息。一般情况下,用户会优先考虑附近的兴趣点而不是更远距离的场所。为解决上述问题,文献[89]设计了一种时间感知的POI嵌入方法,并通过注意力机制动态地选择时间信息,从而实现在目标时间点为用户提供更精准的POI推荐,但该方法忽视了位置因素对用户选择的影响。文献[90]提出融合地理位置影响的区域感知的POI推荐系统,使用语义空间图来建模POI之间的关系。其中,语义层面同时考虑兴趣点的属性特征和类别相似性,空间层面主要考虑不同POI的地理关系,因此模型能够捕获用户兴趣随地理位置的动态变化。

3.5 应用场景总结

现阶段推荐系统已被应用到各行各业,从视频、音乐等娱乐活动,再到餐饮、购物等日常生活^[11]。为了方便读者能够更全面地了解利用知识图谱的推荐系统的应用场景,表3对相关文献和数据集进行了概括总结。

表3 不同应用场景的数据集
Table 3 Datasets for different application scenarios

应用场景	数据集	相关文献
娱乐活动	视频	MovieLens [44][26][28][72][91] DoubanMovie [39]
	音乐	Last.FM [19][34][42][50][27]
	图书	Book-Crossing [44][40][42][27][43] Amazon-Book [19][45] Intent Book [17] DBbook [22][28]
	POI	Yelp Challenge [19][31][37][39]
	新闻	Bing-News [18][25] MIND [81]
	商品	Alibaba-iFashion [45][84] Amazon [37][34][87]
日常生活	餐饮	Dianping-Food [44][50][43]

4 未来展望

本文介绍了现有的利用知识图谱的推荐方法和应用场景。此外,强化学习^[35,92]、对比学习^[48-49]等先进技术也开始在推荐系统中广泛应用。下面对利用知识图谱的推荐系统未来发展进行展望。

4.1 领域知识图谱构建

自从知识图谱概念被提出以来,大规模的通用知识图谱正逐渐完善并广泛应用^[69-71]。然而,推荐任务往往面向具体领域,如影视、电商等。现有推荐系统需要将原始数据集中的项目与公开的通用图谱中的实体进行对齐,从而抽取需要的小规模知识图谱。文献[93]对该过程进行规范,完成了Last.FM^[73]、Amazon-Book^[74]、MovieLens^[75]三个常用数据集与Freebase^[70]知识图谱的

连接操作。但从通用知识图谱中抽取的子图通常存在大量干扰信息,影响推荐算法的准确性。

为进一步提高推荐性能,领域知识图谱的构建和应用至关重要。现有的医疗、金融等领域知识图谱通常用于搜索问答、业务管理等需求,无法直接用来完成推荐任务。因此,需要考虑从推荐任务的需求出发,对现有领域图谱进行剪枝或补全,构建适应具体推荐场景的领域知识图谱。

4.2 噪声数据处理

利用知识图谱的推荐系统依赖于稠密的交互信息数据和高质量的知识图谱,两种数据普遍存在干扰噪声。推荐系统根据用户的反馈数据建模用户偏好,由于评分类的显示数据难以获取,现有模型通常基于隐式反馈数据(如购买、浏览等)进行建模。用户容易受到项目的外在特征(如标题、图片等)欺骗与项目之间产生交互^[94],这种隐式交互数据并不能反映用户的真实偏好,甚至降低用户对推荐系统的信任程度。因此,如何在用户画像过程中降低噪声数据的影响值得进一步研究。

知识图谱中的噪声信息主要来源于与推荐任务无关的实体和关系。这些信息对用户和项目的表示存在负面影响,并且为推荐系统带来额外的计算需求。现有方法在模型训练过程中降低噪声信息权重,但并没有降低算法的复杂度。如何处理噪声数据,减少计算开销应是未来研究的重要方向。

4.3 用户隐私信息保护

推荐系统为用户带来便利的同时增加了隐私信息泄露的风险。在传统推荐算法中,用户的交互数据隐私保护已取得一些进展^[95]。而部分研究者将用户行为数据和项目属性结合构建协同知识图谱进行推荐,现有研究对于该类数据的隐私保护问题关注度较低,尤其是利用知识图谱进行跨域推荐的过程中,借助源域中的数据在目标域中完成推荐任务,容易造成源域隐私信息泄露。

文献[96]指出现有模型大多数假设信息可以直接迁移,而忽略了隐私保护问题。因此,如何在隐私保护的基础上建立利用知识图谱的推荐系统成为一个紧迫的研究问题。

4.4 评估指标多样化

目前,推荐算法性能大多从准确性进行评估,然而不断地提高推荐结果的准确性,可能导致“信息茧房”效应。真正好的推荐系统应该同时兼顾多种评估指标。虽然知识图谱为推荐系统带来了多样性、可解释性等方面性能提升,但现有研究却很少从这些性能上进行评估。文献[97]首次将利用知识图谱的推荐系统与多目标优化算法结合,同时优化推荐的精度、多样性和可解释性,为后续实验评估提供新的研究思路。

此外,学术界推荐系统通常更注重用户的满意度,而工业界推荐系统需要兼顾用户体验和经济效益的转

化,使得平台和用户都能从推荐系统受益。评估推荐系统的好坏可以从稳定性、多样性、内容新颖性、用户满意度、平台收益等多方面进行。

5 结束语

将知识图谱作为辅助信息引入到推荐系统,不仅能够有效缓解传统推荐算法普遍存在的冷启动、数据稀疏问题,同时能够增强推荐结果的整体性能。本文通过对近年来利用知识图谱的推荐系统的相关论文进行调研,较为全面地总结了该领域的研究现状及应用场景,最后讨论了未来发展的几个研究方向,希望能够帮助读者更好地理解该领域的研究工作。

参考文献:

- [1] GUO Q Y, ZHUANG F Z, QIN C, et al. A survey on knowledge graph-based recommender systems[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 50(7): 937-954.
- [2] SACENTI J A P, FILETO R, WILLRICH R. Knowledge graph summarization impacts on movie recommendations[J]. Journal of Intelligent Information Systems, 2022, 58(1): 43-66.
- [3] CHAVES P D V, PEREIRA B L, SANTOS R L. Efficient online learning to rank for sequential music recommendation[C]//Proceedings of the ACM Web Conference. New York: ACM, 2022: 2442-2450.
- [4] QI T, WU F Z, WU C H, et al. Personalized news recommendation with knowledge-aware interactive matching[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 61-70.
- [5] FENG Y F, HU B B, LYU F Y, et al. ATBRG: adaptive target-behavior relational graph network for effective recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 2231-2240.
- [6] LEE D, OH B, SEO S, et al. News recommendation with topic-enriched knowledge graphs[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 695-704.
- [7] TAO S H, QIU R H, PING Y, et al. Multi-modal knowledge-aware reinforcement learning network for explainable recommendation[J]. Knowledge-Based Systems, 2021(227): 107217.
- [8] CHEN B, GUO W, TANG R M, et al. TGCN: tag graph convolutional network for tag-aware recommendation[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 155-164.
- [9] BRAMS A H, JAKOBSEN A L, JENDAL T E, et al. Mind-Reader: recommendation over knowledge graph entities with explicit user ratings[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 2975-2982.
- [10] 秦川, 祝恒书, 庄福振, 等. 基于知识图谱的推荐系统研究综述[J]. 中国科学: 信息科学, 2020, 50(7): 937-956.
- [11] 朱冬亮, 文奕, 万子琛. 基于知识图谱的推荐系统研究综述[J]. 数据分析与知识发现, 2021, 5(12): 1-13.
- [12] ADOMAVICIUS G, TUZHILIN A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions[J]. IEEE Transactions on Knowledge and Data Engineering, 2005, 17(6): 734-749.
- [13] SU X Y, KHOSHGOFTAAR T M. A survey of collaborative filtering techniques[J]. Advances in Artificial Intelligence, 2009, 8: 421-425.
- [14] RENDLE S. Factorization machines with libFM[J]. ACM Transactions on Intelligent Systems and Technology, 2012, 3(3): 57.
- [15] HUANG Z H, YU C, NI J, et al. An efficient hybrid recommendation model with deep neural networks[J]. IEEE Access, 2019, 7: 137900-137912.
- [16] CAO X S, SHI Y L, YU H, et al. DEKR: description enhanced knowledge graph for machine learning method recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 203-212.
- [17] ZHANG F Z, YUAN N J, LIAN D F, et al. Collaborative knowledge base embedding for recommender systems[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 353-362.
- [18] WANG H W, ZHANG F Z, XIE X, et al. DKN: deep knowledge-aware network for news recommendation[C]//Proceedings of the World Wide Web Conference. New York: ACM, 2018: 1835-1844.
- [19] WANG X, HE X N, CAO Y X, et al. KGAT: knowledge graph attention network for recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference. New York: ACM, 2019: 950-958.
- [20] PALUMBO E, RIZZO G, TRONCY R. Entity2Rec: learning user-item relatedness from knowledge graphs for top-n item recommendation[C]//Proceedings of the 11th ACM Conference on Recommender Systems. New York: ACM,

- 2017;32-36.
- [21] 张屹晗,王巍,刘华真,等.基于知识图嵌入的协同过滤推荐算法[J].计算机应用研究,2021,38(12):3590-3596.
ZHANG Y H, WANG W, LIU H Z, et al. Collaborative filtering recommendation algorithm based on knowledge graph embedding[J]. Application Research of Computers, 2021, 38(12): 3590-3596.
- [22] CAO Y X, WANG X, HE X N, et al. Unifying knowledge graph learning and recommendation: towards a better understanding of user preferences[C]//Proceedings of the World Wide Web Conference. New York: ACM, 2019: 151-161.
- [23] HENK V, VAHDATI S, NAYYERI M, et al. Metaresearch recommendations using knowledge graph embeddings [C/OL]//RecNLP Workshop of AAAI Conference (2019-01-28)[2022-09-11]. https://recnlp2019.github.io/papers/RecNLP2019_paper_20.pdf.
- [24] 高仰,刘渊.融合社交关系和知识图谱的推荐算法[J].计算机科学与探索,2023,17(1):238-250.
GAO Y, LIU Y. Recommendation algorithm combining social relationship and knowledge graph[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(1): 238-250.
- [25] AI Q Y, AZIZI V, CHEN X, et al. Learning heterogeneous knowledge base embeddings for explainable recommendation[J]. Algorithms, 2018, 11(9): 137-154.
- [26] WANG Y Q, DONG L Y, ZHANG H, et al. An enhanced multi-modal recommendation based on alternate training with knowledge graph representation[J]. IEEE Access, 2020, 8: 213012-213026.
- [27] WANG H W, ZHANG F Z, ZHAO M, et al. Multi-task feature learning for knowledge graph enhanced recommendation[C]//Proceedings of the World Wide Web Conference. New York: ACM, 2019: 2000-2010.
- [28] POLIGNANO M, MUSTO C, DE GEMMIS M, et al. Together is better: hybrid recommendations combining graph embeddings and contextualized word representations[C]//Proceedings of the 15th ACM Conference on Recommender Systems. New York: ACM, 2021: 187-198.
- [29] 冀婷婷,诺明花.一种融合标签和知识图谱的推荐方法[J].中文信息学报,2022,36(6):125-134.
JI X T, NUO M H. A recommendation method combining tag and knowledge graph[J]. Journal of Chinese Information Processing, 2022, 36(6): 125-134.
- [30] ZHAO X, CHENG Z, ZHU L, et al. UGRec: modeling directed and undirected relations for recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 193-202.
- [31] YU X, REN X, SUN Y Z, et al. Personalized entity recommendation: a heterogeneous information network approach [C]//Proceedings of the 7th ACM International Conference on Web Search and Data Mining. New York: ACM, 2014: 283-292.
- [32] ZHANG C, WANG Y, ZHU L, et al. Multi-graph heterogeneous interaction fusion for social recommendation[J]. ACM Transactions on Information Systems, 2021, 40(2): 1-26.
- [33] DONG Y X, CHAWLA N V, SWAMI A. metapath2vec: scalable representation learning for heterogeneous networks[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2017: 135-144.
- [34] HU B B, SHI C, ZHAO W X, et al. Leveraging meta-path based context for top-n recommendation with a neural co-attention model[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2018: 1531-1540.
- [35] XIAN Y K, FU Z H, MUTHUKRISHNAN S, et al. Reinforcement knowledge graph reasoning for explainable recommendation[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2019: 285-294.
- [36] CHEN H X, LI Y C, SUN X G, et al. Temporal meta-path guided explainable recommendation[C]//Proceedings of the 14th ACM International Conference on Web Search and Data Mining. New York: ACM, 2021: 1056-1064.
- [37] ZHAO H, YAO Q M, LI J D, et al. Meta-graph based recommendation fusion over heterogeneous information networks[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2017: 635-644.
- [38] HAN Z Y, XU F L, SHI J H, et al. Genetic meta-structure search for recommendation on heterogeneous information network[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 455-464.
- [39] HUANG Z P, ZHENG Y D, CHENG R, et al. Meta structure: computing relevance in large heterogeneous information networks[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 1595-1604.
- [40] WANG H W, ZHANG F Z, WANG J L, et al. RippleNet: propagating user preferences on the knowledge graph for recommender systems[C]//Proceedings of the 27th ACM International Conference on Information & Knowledge Management. New York: ACM, 2018: 417-426.
- [41] 张雪茹,官磊.基于知识图谱的用户偏好推荐算法[J].计算机应用,2021,40(S2):59-65.
ZHANG X R, GUAN L. User preference recommendation algorithm based on knowledge graph[J]. Application Research

- of Computers, 2021, 40(S2): 59-65.
- [42] WANG H W, ZHAO M, XIE X, et al. Knowledge graph convolutional networks for recommender systems[C]// Proceedings of the World Wide Web Conference, 2019: 3307-3313.
- [43] WANG H W, ZHANG F Z, ZHANG M D, et al. Knowledge graph convolutional networks for recommender systems with label smoothness regularization[C]// Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2019: 968-977.
- [44] WANG Z, LIN G Y, TAN H B, et al. CKAN: collaborative knowledge-aware attentive network for recommender systems[C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 219-228.
- [45] WANG X, HUANG T L, WANG D X, et al. Learning intents behind interactions with knowledge graph for recommendation[C]// Proceedings of the Web Conference, 2021: 878-887.
- [46] 唐宏, 范森, 唐帆. 融合协同知识图谱与优化图注意网络的推荐算法[J]. 计算机工程与应用, 2022, 58(19): 98-106.
- TANG H, FAN S, TANG F. Recommendation algorithm integrating collaborative knowledge graph and optimizing graph attention network[J]. Computer Engineering and Applications, 2022, 58(19): 98-106.
- [47] TANG X L, WANG T Y, YANG H Z, et al. AKUPM: attention-enhanced knowledge-aware user preference model for recommendation[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2019: 1891-1899.
- [48] YANG Y H, HUANG C, XIA L H, et al. Knowledge graph contrastive learning for recommendation[C]// Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1434-1443.
- [49] ZOU D, WEI W, MAO X L, et al. Multi-level cross-view contrastive learning for knowledge-aware recommender system[C]// Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1358-1368.
- [50] TU K, CUI P, WANG D X, et al. Conditional graph attention networks for distilling and refining knowledge graphs in recommendation[C]// Proceedings of the 30th ACM International Conference on Information & Knowledge Management. New York: ACM, 2021: 1834-1843.
- [51] LIU D Y, LIAN J, WANG S Y, et al. KRED: knowledge-aware document representation for news recommendations[C]// Processing of the 14th ACM Conference on Recommender Systems, 2020: 200-209.
- [52] TIAN Y, YANG Y H, REN X D, et al. Joint knowledge pruning and recurrent graph convolution for news recommendation[C]// Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 51-60.
- [53] WANG Q, MAO Z D, WANG B, et al. Knowledge graph embedding: a survey of approaches and applications[J]. IEEE Transactions on Knowledge and Data Engineering, 2017, 29(12): 2724-2743.
- [54] BORDES A, USUNIER N, GARCIA D A, et al. Translating embeddings for modeling multi-relational data[C]// Advances in Neural Information Processing Systems, 2013, 26: 1-9.
- [55] WANG Z, ZHANG J W, FENG J L, et al. Knowledge graph embedding by translating on hyperplanes[C]// Proceedings of the 28th AAAI Conference on Artificial Intelligence, 2014.
- [56] LIN Y K, LIU Z Y, SUN M S, et al. Learning entity and relation embeddings for knowledge graph completion[C]// Proceedings of the 29th AAAI Conference on Artificial Intelligence, 2015: 2181-2187.
- [57] JI G L, HE S Z, XU L H, et al. Knowledge graph embedding via dynamic mapping matrix[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing, 2015: 687-696.
- [58] HE S Z, LIU K, JI G L, et al. Learning to represent knowledge graphs with gaussian embedding[C]// Proceedings of the 24th ACM International Conference on Information & Knowledge Management. New York: ACM, 2015: 623-632.
- [59] HAN X, HUANG M L, ZHU X Y. TransG: a generative model for knowledge graph embedding[C]// Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, 2016: 2316-2325.
- [60] YANG B S, YIH W, HE X D, et al. Embedding entities and relations for learning and inference in knowledge bases[J]. Arxiv: 1412.6575, 2014.
- [61] CHEN C, ZHANG M, WANG C Y, et al. An efficient adaptive transfer neural network for social-aware recommendation[C]// Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2019: 225-234.
- [62] BORDES A, GLOROT X, WESTON J, et al. A semantic matching energy function for learning with multi-relational data[J]. Machine Learning, 2014, 94(2): 233-259.
- [63] DONG X, GABRILOVICH E, HEITZ G, et al. Knowledge vault: a web-scale approach to probabilistic knowledge fusion[C]// Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2014: 601-610.
- [64] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training

- of deep bidirectional transformers for language understanding[J].arXiv:1810.04805,2018.
- [65] CHEN T Q,ZHANG W N,LU Q X,et al.SVDFeature: a toolkit for feature-based collaborative filtering[J].The Journal of Machine Learning Research,2012,13(1): 3619-3622.
- [66] WANG Y,LIU Z W,FAN Z W,et al.DSKREG:differentiable sampling on knowledge graph for recommendation with relational GNN[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management.New York:ACM,2021:3513-3517.
- [67] ZHAO W X,MU S,HOU Y,et al.Recbole:towards a unified,comprehensive and efficient framework for recommendation algorithms[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management.New York:ACM,2021:4653-4664.
- [68] AIOLLI F.Efficient top-n recommendation for very large scale binary rated datasets[C]//Proceedings of the 7th ACM Conference on Recommender Systems.New York:ACM, 2013:273-280.
- [69] LEHMANN J,ISELE RT,JAKOB M,et al.DBpedia-a large-scale,multilingual knowledge base extracted from Wikipedia[J].Semantic Web,2015,6(2):167-195.
- [70] BOLLACKER K,EVANS C,PARITOSH P,et al.Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data.New York: ACM,2008:1247-1250.
- [71] SUCHANEK F M,KASNECI G,WEIKUM G.YAGO:a core of semantic knowledge[C]//Proceedings of the 16th International Conference on World Wide Web.New York: ACM,2007:697-706.
- [72] TAI C Y,WU M G,CHU Y W,et al.MVIN:learning multiview items for recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval.New York:ACM, 2020:99-108.
- [73] SCHEDL M.The LFM-1b dataset for music retrieval and recommendation[C]//Proceedings of the ACM on International Conference on Multimedia Retrieval.New York: ACM,2016:103-110.
- [74] MCAULEY J,TARGETT C,SHI Q,et al.Image-based recommendations on styles and substitutes[C]//Proceedings of the 38th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York:ACM,2015:43-52.
- [75] GroupLens MovieLens dataset[EB/OL].(1997)[2022-08-18]. <https://grouplens.org/datasets/movielens/>.
- [76] YANG D Q,GUO Z K,WANG Z Y,et al.A knowledge-enhanced deep recommendation framework incorporating GAN-based models[C]//Proceedings of the 2018 IEEE International Conference on Data Mining.Piscataway:IEEE,2018: 1368-1373.
- [77] ZIEGLER C N,MCNEE S M,KONSTAN J A,et al. Improving recommendation lists through topic diversification[C]//Proceedings of the 14th International Conference on World Wide Web,2005:22-32.
- [78] ZHOU K,WANG X L,ZHOU Y H,et al.CRSLab:an open-source toolkit for building conversational recommender system[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations,2021:185-193.
- [79] ZHOU K,ZHAO W X,BIAN S Q,et al.Improving conversational recommender systems via knowledge graph based semantic fusion[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.New York:ACM,2020:1006-1014.
- [80] SUN F Y,HOFFMANN J,VERMA V,et al.InfoGraph: unsupervised and semi-supervised graph-level representation learning via mutual information maximization[J]. arXiv:1908.01000,2019.
- [81] WU F Z,QIAO Y,CHEN J H,et al.MIND:a large-scale dataset for news recommendation[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics,2020:3597-3606.
- [82] QI TAO,WU F Z,WU C H,et al.PP-Rec:news recommendation with personalized user interest and time-aware news popularity[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing,2021:5457-5467.
- [83] VELICKOVIC P,CUCURULL G,CASANOVA A,et al. Graph attention networks[C]//Proceedings of the 2018 International Conference on Learning Representations,2018:12-23.
- [84] WU J C,WANG X,FENG F L,et al.Self-supervised graph learning for recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval.New York:ACM, 2021:726-735.
- [85] CHEN W,HUANG P P,XU J M,et al.POG:personalized outfit generation for fashion recommendation at Alibaba iFashion[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.New York:ACM,2019:2662-2670.
- [86] 沈冬东,汪海涛,姜瑛,等.基于知识图谱嵌入与神经网络的序列推荐算法[J].计算机工程与科学,2020,42(9): 1661-1669.
- SHEN D D,WANG H T,JIANG Y,et al.A sequeue recommendation algorithm based on knowledge graph embed-

- ding and multiple neural networks[J].Computer Engineer and Science, 2020, 42(9):1661-1669.
- [87] WANG C Y, ZHANG M, MA W Z, et al. Make it a chorus: knowledge-and time-aware item modeling for sequential recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Processing Information Retrieval. New York: ACM, 2020:109-118.
- [88] Yelp challenge dataset[EB/OL]. (2013)[2022-08-18]. <https://www.kaggle.com/c/yelp-recsys-2013/>.
- [89] SHI M H, SHEN D R, KOU Y, et al. Attentional memory network with correlation-based embedding for time-aware POI recommendation[J]. Knowledge-Based Systems, 2021 (214):106747.
- [90] TANG J K, JIN J H, MIAO Z J, et al. Region-aware POI recommendation with semantic spatial graph[C]//Proceedings of the 24th International Conference on Computer Supported Cooperative Work in Design, 2021:214-219.
- [91] SUN R, CAO X Z, ZHAO Y, et al. Multi-modal knowledge graphs for recommender systems[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 1405-1414.
- [92] ZHAO K Z, WANG X T, ZHANG Y R, et al. Leveraging demonstrations for reinforcement recommendation reasoning over knowledge graphs[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020:239-248.
- [93] ZHAO W X, HE G, YANG K, et al. KB4Rec: a data set for linking knowledge bases with recommender systems[J]. Data Intelligence, 2019, 1(2):121-136.
- [94] WANG W, FENG F, HE X, et al. Clicks can be cheating: counterfactual recommendation for mitigating clickbait issue[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021:1288-1297.
- [95] LI T, SONG L, FRAGOULI C. Federated recommendation system via differential privacy[C]//2020 IEEE International Symposium on Information Theory. Piscataway: IEEE, 2020:2592-2597.
- [96] CHEN C, WU H, SU J, et al. Differential private knowledge transfer for privacy-preserving cross-domain recommendation[C]//Proceedings of the ACM Web Conference 2022. New York: ACM, 2022:1455-1465.
- [97] XIE L, HU Z, CAI X, et al. Explainable recommendation based on knowledge graph and multi-objective optimization[J]. Complex & Intelligent Systems, 2021, 7(3): 1241-1252.